

Super-Resolution e Limitazioni di Risoluzione

Gli algoritmi di interpolazione, pur riducendo la dimensione del *voxel*, **non possono migliorare la risoluzione “fisica”** dell’immagine, la quale è limitata dall’**Effetto Volume Parziale (PVE)**.

9.1 Conseguenze del PVE sulla Rilevabilità

Modelliamo il caso di un nodulo sferico (raggio R , segnale S_1) immerso in un tessuto circostante (segnale S_2). Se la scansione è eseguita con un *voxel* cubico di dimensione $2R \times 2R \times 2R$ (il *voxel* ha la stessa dimensione del nodulo), il **Contrasto-Rumore (CNR)** misurato tra il nodulo e il tessuto circostante è dato da:

$$CNR_{misurato} = \frac{|M_1 - M_2|}{\sigma} = p \frac{|S_1 - S_2|}{\sigma} = p \cdot CNR_{ideale}$$

Dove M_1 e M_2 sono i segnali misurati, e p è il **fattore di riempimento** del *voxel* dovuto al nodulo. La relazione mostra che il CNR misurato è una frazione (p) del CNR ideale.

- **Caso Migliore:** Sfera perfettamente inscritta nel *voxel* $\Rightarrow p \approx \pi/6 \approx 0.52$. Il CNR si riduce di circa il **50%**.
- **Caso Peggior:** Sfera inclusa in modo simmetrico in otto *voxel* $\Rightarrow p \approx \pi/48 \approx 0.065$. Il CNR si riduce al circa **6%** del valore teorico.

Conclusioni Cliniche: Se la soglia di CNR per la visibilità è intermedia tra i due casi, la visibilità del nodulo non è prevedibile e dipende dalla posizione casuale della sfera rispetto alla griglia di acquisizione del sistema di imaging. La “certezza” di osservare l’oggetto si ha solo quando le sue dimensioni sono tali da saturare con sicurezza almeno un intero *voxel*.

9.1.1 Esempio Semplificativo di PVE 2D L’esempio mostra come il PVE possa influenzare drasticamente il valore misurato (segnale) in un’immagine a Bassa Risoluzione (LR), a parità di oggetto. !Pasted image 20251129164945.png

- **Immagine HR (2048x2048):** Cerchio con $S_1 = 1000$, fondo $S_2 = 100$, raggio $r = 128$.
- **Interpolazione LR (8x8, passo 256):**
 - **Cerchio centrato in un pixel LR:** Il cerchio si riduce a un unico pixel di valore ≈ 806 .
 - **Cerchio diviso in quattro pixel LR:** Si ottengono quattro pixel LR con valore ≈ 276 .

Il **contrasto varia con lo sfasamento** tra il *voxel* LR e l’oggetto, rendendo il fenomeno imprevedibile.

9.2 Concetto di Super-Resolution

L’idea alla base delle tecniche di **Super-Resolution (SR)** è quella di combinare immagini diverse della stessa struttura anatomica per ottenere una **migliore risoluzione spaziale** (migliore del PVE).

L’ipotesi teorica è che, ripetendo l’acquisizione più volte e variando la posizione dell’oggetto o della griglia, si possa prima o poi ottenere il caso ottimale di massimo riempimento (*voxel*).

9.2.1 Applicazione in MRI Nelle tecniche SR si combinano *voxel* anisotropi per migliorare la risoluzione spaziale sull'asse perpendicolare al piano di acquisizione (la *slice-select direction*).

- **Esempio:** Acquisizione cardiaca MRI su piani diversi (asse corto, 2/3/4 camere). Ogni immagine ha risoluzione spaziale fortemente anisotropica (e.g., $1.7 \times 1.7 \times 8$ mm).
- **Combinazione:** Le immagini multiple vengono combinate (es. acquisizioni su piani perpendicolari o “interallacciate” con distanza inter-slice frazionaria) per ricreare un *voxel* isotropo a risoluzione più alta.

Nota sulle Immagini Dinamiche: Lo stesso concetto si applica a una serie temporale di immagini, ma è necessario compensare la deformazione della struttura dell'organo (movimenti) con **algoritmi di registrazione**.

Capitolo 10: Modello Matematico e Soluzione del Problema

10.1 Il Modello di Acquisizione Super-Resolution

Il problema della *Super-Resolution* si descrive come un processo inverso che cerca di risalire all'immagine ideale ad alta risoluzione X a partire da N immagini a bassa risoluzione Y_k .

Per $k = 1, \dots, N$:

$$Y_k = D_k T_k h_k X + n_k$$

- X : Immagine “ideale” ad **Alta Risoluzione (HR)**.
- Y_k : Le N immagini a **Bassa Risoluzione (LR)** disponibili (immagini reali).
- D_k : Processo di **Downsampling** (riduzione del numero di pixel di X).
- T_k : **Trasformazione geometrica** (posizione della griglia di acquisizione + deformazione, es. per movimento del paziente).
- h_k : Effetto **Volume Parziale (PVE)**, modellato come una convoluzione con un kernel gaussiano 2D o 3D, spesso anisotropico.
- n_k : **Rumore** indotto dal sistema di imaging.

Se la risoluzione spaziale e la distribuzione del rumore sono le stesse per tutte le acquisizioni: $h_1 = \dots = h_N = h$ e $D_1 = \dots = D_N = D$.

10.2 Soluzione del Problema Inverso: *Iterated Back-Projection*

Stimare X da Y_k è un tipico **problema inverso**, generalmente “**mal posto**” (ovvero non ha una soluzione univoca). Il modo più semplice per risolverlo è l'algoritmo di **Iterated Back-Projection**.

10.2.1 Passaggi dell'Algoritmo 1. Stima Iniziale ($\hat{X}^{(0)}$): Si parte da una stima di X (ottenuta ad esempio interpolando una singola immagine Y_k alle dimensioni HR).

2. Simulazione dell'Acquisizione (Stima LR): Si simula il processo di acquisizione per ottenere la stima delle immagini LR $\hat{Y}_k^{(n)}$ (dove n è il passo iterativo) a partire dalla stima HR corrente $\hat{X}^{(n)}$.

$$\hat{Y}_k^{(n)} = D T_k h \hat{X}^{(n)}$$

(D e h devono essere congruenti al rapporto tra le risoluzioni HR e LR).

3. Calcolo del Gradiente di Errore (G_k): Si calcola la differenza (errore) tra l'immagine LR stimata e quella reale misurata:

$$G_k = Y_k - \hat{Y}_k^{(n)}$$

4. Proiezione Inversa del Gradiente (G): Si calcola il gradiente complessivo G da usare per aggiornare X , riallineando le mappe di errore G_k con la trasformazione geometrica inversa T_k^{-1} :

$$G = \sum_{k=1}^N D T_k^{-1} G_k$$

5. Aggiornamento Iterativo di X : Si calcola la nuova stima di X aggiungendo il gradiente G pesato e filtrato:

$$\hat{X}^{(n+1)} = \hat{X}^{(n)} + \lambda G^{(n)} * H$$

- λ : Tasso di convergenza (alto: rischio di non convergenza; basso: aumento delle iterazioni).
- H : Kernel di un filtro che ottimizza la convergenza (spesso scelto $H = h$).

Il processo prosegue finché la differenza percentuale tra $\hat{X}$ stimati a due passi successivi non scende sotto una certa soglia.

10.2.2 Minimizzazione e Regolarizzazione L'algoritmo minimizza l'errore quadratico medio tra le immagini LR misurate e quelle stimate:

$$\mathcal{E}^{(n)} = \sqrt{\sum_{k=1}^N (Y_k - \hat{Y}_k^{(n)})^2}$$

Poiché il problema è mal posto, la soluzione non è unica e può dipendere dalla scelta delle condizioni iniziali $\hat{X}^{(0)}$. Per stabilizzare la soluzione, si introducono **condizioni di regolarizzazione**, che impongono ipotesi *a priori* (es. che X sia “smooth”).

In presenza di regolarizzazione, viene minimizzata una metrica che include un termine di penalità:

$$\mathcal{E} = \sum_{k=1}^N (Y_k - \hat{Y}_k^{(n)})^2 + \gamma \|\mathcal{C} \hat{X}\|^2$$

- $\mathcal{C}$: Operatore di filtraggio di tipo **passa-alto** (es. il gradiente dell'immagine).
- γ : Costante che rappresenta il peso della regolarizzazione.

La presenza del filtro $\mathcal{C}$ penalizza le soluzioni con bruschi cambiamenti di segnale, ottenendo l'immagine HR più “regolare” (*smooth*). Altri algoritmi noti per la SR includono il *Deterministic Regularized Approach* e lo *Statistical Regularized Approach*.
