

## Test Statistici e Diagnosi

Questo capitolo tratta due aspetti fondamentali della validazione in ambito biomedico:

1. **Test di significatività statistica** - per determinare se le differenze osservate sono reali
2. **Misure di efficacia diagnostica** - per valutare la capacità di identificare patologie

---

### 1. Test di Significatività Statistica

#### 1.1 L'Ipotesi Nulla

Di larghissimo uso nella valutazione delle metodiche per l'estrazione di indici clinici è l'**indice p** (p-value), che rappresenta la probabilità di accettazione dell'**ipotesi nulla** ( $H_0$ ).

□ **Info:** Definizione

L'**ipotesi nulla** afferma che non esiste alcuna differenza tra le due misure riguardo al parametro considerato. Le eventuali differenze osservate vanno attribuite al solo caso.

**Implicazione clinica:** Due misure statisticamente equivalenti possono essere usate in modo **interscambiabile** nella valutazione clinica.

#### 1.2 Il Test di Significatività

L'ipotesi nulla può essere accettata o respinta applicando un **test statistico di significatività**:

1. Calcolare la statistica del test
2. Confrontare con un valore critico tabulato
3. Se il risultato **supera** il valore critico → differenza **statisticamente significativa** →  $H_0$  respinta
4. Altrimenti →  $H_0$  accettata

#### 1.3 Il P-value

Il parametro **p** esprime la probabilità che l'ipotesi nulla sia falsa:

| Valore p      | Interpretazione                    |
|---------------|------------------------------------|
| $p < 0.01$    | Differenza altamente significativa |
| $p < 0.05$    | Differenza significativa           |
| $p \geq 0.05$ | Differenza non significativa       |

□ **Attenzione:** Attenzione

Un p-value basso (es.  $p < 0.05$ ) indica che i due gruppi sono **diversi**, non equivalenti. Nel caso della validazione, vogliamo  $p \geq 0.05$  per confermare l'equivalenza.

## 1.4 Errori nei Test Statistici

| Tipo           | Nome           | Descrizione                    | Probabilità                           |
|----------------|----------------|--------------------------------|---------------------------------------|
| <b>Tipo I</b>  | Falso Positivo | Rifiutare $H_0$ quando è vera  | $\alpha$ (livello di significatività) |
| <b>Tipo II</b> | Falso Negativo | Accettare $H_0$ quando è falsa | $\beta$                               |

La **potenza** del test è definita come  $1 - \beta$ : capacità di rilevare differenze reali.

## 1.5 Paired t-Test

Il **paired t-test** (test t per campioni appaiati) si applica quando la misura è effettuata:

- Da due osservatori sulla **stessa immagine**
- Con due metodi sullo **stesso paziente**

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}$$

dove:

- $\bar{d}$  = media delle differenze
- $s_d$  = deviazione standard delle differenze
- $n$  = numero di coppie

### Applicazioni:

- Valutazione vs. gold standard
- Intra-observer variability
- Inter-observer variability

□ **Esempio:** Esempio Clinico: Misura del Ferro Epatico

Confronto tra due software per la misura dell'accumulo di ferro in pazienti talassemici (20 immagini):

| Gruppo              | p-value      | Conclusione                            |
|---------------------|--------------|----------------------------------------|
| Senza accumulo      | $p = 0.0776$ | Non significativo → metodi equivalenti |
| Con accumulo severo | $p < 0.0001$ | Significativo → metodi diversi         |

**Nota:** Il paired t-test è sensibile all'**errore sistematico**. Una differenza di 0.55 su media 38.5 (1.5%) può già creare significatività.

## 1.6 Altri Test Statistici

| Test                        | Applicazione                                       | Requisiti                    |
|-----------------------------|----------------------------------------------------|------------------------------|
| <b>t-test indipendente</b>  | Gruppi diversi                                     | Normalità, varianze omogenee |
| <b>Wilcoxon signed-rank</b> | Alternativa non parametrica al paired t-test       | Dati ordinali                |
| <b>Mann-Whitney U</b>       | Alternativa non parametrica al t-test indipendente | Dati ordinali                |
| <b>ANOVA</b>                | Confronto > 2 gruppi                               | Normalità, varianze omogenee |
| <b>Bland-Altman</b>         | Agreement tra metodi                               | Visualizzazione grafica      |

## 2. Misure di Efficacia Diagnostica

La validità di un metodo di analisi può essere valutata in base all'**efficacia nell'identificare una malattia**.

### 2.1 Matrice di Confusione

Data una popolazione di K pazienti:

- M = pazienti **malati**
- S = pazienti **sani** ( $K = M + S$ )

|                      | Condizione Reale: Malato | Condizione Reale: Sano |
|----------------------|--------------------------|------------------------|
| <b>Test Positivo</b> | VP (Vero Positivo)       | FP (Falso Positivo)    |
| <b>Test Negativo</b> | FN (Falso Negativo)      | VN (Vero Negativo)     |

### 2.2 Metriche Fondamentali

### Sensibilità (Recall, True Positive Rate)

$$\text{Sensibilità} = \frac{VP}{VP + FN} = \frac{VP}{M}$$

□ **Suggerimento:** Interpretazione

Capacità del metodo di **scoprire la patologia**. Percentuale di diagnosi giuste sui soggetti **malati**.

### Specificità (True Negative Rate)

$$\text{Specificità} = \frac{VN}{VN + FP} = \frac{VN}{S}$$

□ **Suggerimento:** Interpretazione

Capacità del metodo di fare una **diagnosi corretta sui pazienti sani**.

### Accuratezza

$$\text{Accuratezza} = \frac{VP + VN}{VP + VN + FP + FN} = \frac{VP + VN}{K}$$

□ **Suggerimento:** Interpretazione

Percentuale totale di **diagnosi corrette**.

### Valore Predittivo Positivo (Precisione)

$$PPV = \frac{VP}{VP + FP}$$

Probabilità che un test positivo sia corretto.

### Valore Predittivo Negativo

$$NPV = \frac{VN}{VN + FN}$$

Probabilità che un test negativo sia corretto.

## 2.3 Trade-off Sensibilità vs Specificità

□ **Attenzione:** Compromesso Clinico

**Alta sensibilità** (pochi FN) → rischio di FP → sovra-diagnosi **Alta specificità** (pochi FP) → rischio di FN → sotto-diagnosi

La scelta dipende dal **contesto clinico** e dal rapporto **costo/beneficio** degli errori.

| Scenario          | Priorità                                 |
|-------------------|------------------------------------------|
| Screening tumori  | Alta sensibilità (non perdere malati)    |
| Test confermativi | Alta specificità (evitare falsi allarmi) |

## 3. Curve ROC (Receiver Operating Characteristic)

### 3.1 Costruzione della Curva ROC


Una curva ROC visualizza il **trade-off** tra sensibilità e specificità al variare di una soglia decisionale.

**Procedura:**

1. Si ha un vettore  $X = (x_1, x_2, \dots, x_N)$  di misure continue
2. Si ha un indice binario  $I = (i_1, i_2, \dots, i_N)$  indicante presenza/assenza patologia
3. Si fa variare una soglia  $T$
4. Per ogni  $T$ : si classificano come patologici i soggetti con  $x > T$
5. Si calcolano sensibilità e specificità
6. Si riportano i punti nel grafico (1-Specificità, Sensibilità)

### 3.2 Interpretazione della Curva

Sensibilità



| Punto/Curva                       | Significato                           |
|-----------------------------------|---------------------------------------|
| Origine (0,0)                     | Osservatore che dice sempre "NO"      |
| (1,1)                             | Osservatore che dice sempre "SI"      |
| Diagonale                         | Test <b>non informativo</b> (casuale) |
| Curva → angolo superiore sinistro | Test <b>ottimo</b>                    |

### 3.3 Area Under the Curve (AUC)

L'**AUC** (Area Under the ROC Curve) è una misura globale di performance:

| AUC       | Interpretazione                        |
|-----------|----------------------------------------|
| 1.0       | Classificatore perfetto                |
| 0.9 - 1.0 | Eccellente                             |
| 0.8 - 0.9 | Buono                                  |
| 0.7 - 0.8 | Discreto                               |
| 0.5 - 0.7 | Scarso                                 |
| 0.5       | Casuale (nessun potere discriminativo) |

□ **Info:** Interpretazione Probabilistica

L'AUC rappresenta la probabilità che un soggetto malato scelto casualmente abbia un valore del test maggiore di un soggetto sano scelto casualmente.

### 3.4 Punto Ottimale sulla Curva ROC


Il **punto operativo ottimale** dipende dal contesto clinico:


1. **Massima accuratezza:** punto più vicino all'angolo (0,1)
2. **Youden's J statistic:** massimizza  $J = \text{Sensibilità} + \text{Specificità} - 1$
3. **Costo-beneficio:** considera i costi relativi di FP e FN

$$\text{Distanza} = \sqrt{(1 - \text{Sensibilità})^2 + (1 - \text{Specificità})^2}$$

## 4. Applicazione alla Validazione Software

### 4.1 Workflow di Validazione





## 4.2 Metriche Riassuntive

| Contesto                       | Metrica Principale                                  |
|--------------------------------|-----------------------------------------------------|
| <b>Misure continue</b>         | p-value (paired t-test), correlazione, Bland-Altman |
| <b>Classificazione binaria</b> | Sensibilità, Specificità, AUC                       |
| <b>Multi-classe</b>            | Matrice di confusione, F1-score                     |

## Riepilogo

| Concetto             | Descrizione                                                                     |
|----------------------|---------------------------------------------------------------------------------|
| <b>P-value</b>       | Probabilità che $H_0$ sia vera; $p < 0.05 \rightarrow$ differenza significativa |
| <b>Paired t-test</b> | Test per confronto di misure appaiate                                           |
| <b>Sensibilità</b>   | $VP/(VP + FN)$ - capacità di identificare malati                                |
| <b>Specificità</b>   | $VN/(VN + FP)$ - capacità di identificare sani                                  |
| <b>Curva ROC</b>     | Grafico sensibilità vs (1-specificità)                                          |
| <b>AUC</b>           | Area sotto la curva ROC; 1.0 = perfetto, 0.5 = casuale                          |