

Training e Ottimizzazione delle Reti Neurali

Pre-processing dei Dati

L'input della rete è una matrice X di dimensioni $N \times D$: - N = numero di campioni - D = dimensione dei dati (es. numero di pixel)

Normalizzazione

Come per gli algoritmi di clustering, è essenziale **normalizzare** i dati:

Operazione	Formula	Scopo
Mean subtraction	$X' = X - \mu$	Centrare i dati in zero
Standardization	$X' = \frac{X - \mu}{\sigma}$	Media 0, SD 1

!Pasted image 20251201191859.png

Suggerimento: Per immagini Spesso si sottrae la **media del training set** da tutte le immagini (training e test).

Pre-processing per Immagini Biomediche

Le immagini biomediche richiedono passaggi specifici:

1. Cropping

Se la rete analizza un singolo organo: - **Isolare** la regione di interesse - Eliminare aree non rilevanti
- Può richiedere una **segmentazione preliminare**

2. Windowing

Per immagini a 12-16 bit da usare con reti progettate per 8 bit:

$$I_{8bit} = \text{clip} \left(\frac{I - W_L}{W_W} \times 255 \right)$$

Dove: - W_L = window level (centro) - W_W = window width (ampiezza)

3. Filtraggio

Riduzione del rumore prima del training può migliorare le prestazioni.

Regolarizzazione

Tecniche per prevenire l'**overfitting**:

L2 Regularization (Weight Decay)

Aggiunge alla loss il termine:

$$\lambda \sum_{k,l} W_{k,l}^2$$

- Penalizza pesi grandi
- Distribuisce i pesi $\rightarrow$ migliore generalizzazione

L1 Regularization

$$\lambda \sum_{k,l} |W_{k,l}|$$

- Porta molti pesi a **zero** (sparsità)
- Utile per feature selection

Dropout

Durante il training, **disattiva casualmente** una frazione dei neuroni (es. 50%): - Ogni neurone ha probabilità p di essere “spento” - Impedisce la co-adattamento dei neuroni - Equivale a un ensemble di sottoreti

Batch Normalization

Normalizza l'output di ogni layer:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

- Accelera il training
- Permette learning rate più alti
- Ha anche effetto regolarizzante

Loss Function

Classification Loss

Per classificazione multi-classe:

$$L = -\frac{1}{N} \sum_i \log \left(\frac{e^{f_{y_i}}}{\sum_j e^{f_j}} \right) + \lambda R(W)$$

Monitoring del Training

Loss vs Epochs:

Comportamento	Interpretazione
Loss decresce stabilmente	Training corretto
Loss oscillante	Learning rate troppo alto
Loss stazionaria	Learning rate troppo basso o minimo locale
Training loss $\downarrow$, validation loss $\uparrow$	Overfitting

Comportamento	Interpretazione
---------------	-----------------

Data Augmentation

Il Problema del Dataset

In ambito biomedico, ottenere grandi dataset è difficile per: - **Rarità** di alcune patologie - **Privacy** dei pazienti - Difficoltà di coinvolgere esperti per l'**etichettatura** - Formati proprietari non standardizzati

Il Paradosso dell'Accuratezza

Un dataset **sbilanciato** (es. pochi casi patologici) porta a: - Accuratezza apparentemente alta - Ma il modello classifica tutto come classe maggioritaria - Non è un buon classificatore!

Data Augmentation: La Soluzione

Aumentare **artificialmente** il dataset generando varianti delle immagini esistenti.

Due approcci:

Tipo	Descrizione
Static	Immagini generate prima del training e salvate
On-the-fly	Immagini generate durante il training (ogni epoca diversa)

Tecniche di Augmentation

Trasformazioni Geometriche

Trasformazione	Descrizione
Rotazione	Ruotare di angoli casuali
Traslazione	Spostare l'immagine
Scaling	Ingrandire/ridurre
Flip	Capovolgimento orizzontale/verticale
Cropping	Estrarre porzioni casuali
Shearing	Deformazione affine

Attenzione: Attenzione Alcune trasformazioni non hanno senso per certi domini (es. flip verticale di radiografie del torace).

Filtraggio

- **Smoothing** (Gaussian blur con diversi σ)
- **Sharpening**
- Variazione del **windowing** (per immagini biomediche)

Aggiunta di Rumore

- Rumore gaussiano con diversa intensità
- Simula variabilità degli scanner

Elastic Deformation Deformazioni locali non rigide, utili per tessuti biologici.

Info: Nota Le operazioni di filtraggio e rumore corrispondono a variare i parametri del **modello dell'immagine biomedica** visto nel primo capitolo.

Transfer Learning

Il Problema

Addestrare una CNN da zero richiede: - Dataset enormi (milioni di immagini) - Potenza computazionale significativa - Tempo di training lungo

In campo biomedico, questi dataset sono raramente disponibili.

La Soluzione: Transfer Learning

1. Partire da una rete **pre-addestrata** su un grande dataset (es. ImageNet)
2. **Adattare** (fine-tune) la rete al nuovo problema

Approcci di Transfer Learning

Approccio	Dati disponibili	Cosa fare
Feature extraction	Pochi	Congelare tutti i layer, allenare solo il classificatore finale
Fine-tuning	Medio	Congelare i primi layer, allenare gli ultimi
Full fine-tuning	Molti	Allenare tutta la rete con learning rate basso

Perché Funziona?

I primi layer di una CNN catturano **feature generiche** (edge, texture, forme semplici) che sono utili per qualsiasi immagine. Solo i layer finali sono specifici del task.

Risorse per Dataset Biomedici

- ImageNet (immagini generiche): <https://www.image-net.org/>
 - Medical imaging repositories: <https://www.aylward.org/notes/open-access-medical-image-repositories>
 - Grand Challenges in Medical Imaging: <https://grand-challenge.org/>
-

Ottimizzazione del Training

Info: Teoria dell'Ottimizzazione Per una trattazione teorica più ampia, inclusi il teorema No Free Lunch, la legge di Amdahl e gli ottimizzatori globali, vedi Ottimizzatori Globali nella sezione Registrazione.

Monitoraggio

Curve da osservare: 1. **Training loss** vs epochs 2. **Validation loss** vs epochs 3. **Training accuracy** vs epochs 4. **Validation accuracy** vs epochs

Sintomi e Diagnosi

Sintomo	Diagnosi	Rimedio
Loss non decresce	Learning rate troppo basso	Aumentare LR
Loss esplode	Learning rate troppo alto	Diminuire LR
Training loss ↓, val loss ↑	Overfitting	Più regularizzazione, data augmentation
Entrambe le loss stazionarie	Modello troppo semplice	Aumentare capacità

Ispezione dei Layer

Attivazioni

- Visualizzare le attivazioni durante il forward pass
- Molte attivazioni nulle → rete bloccata (learning rate troppo alto?)

Pesi

- Visualizzare i filtri del primo layer convolutivo
- Filtri ben definiti → rete sta imparando
- Filtri rumorosi → overfitting o training insufficiente

Hyperparameter Tuning

Parametri principali: - Learning rate - Batch size - Numero di layer/filtri - Dropout rate - Regularization strength

Strategie: - Grid search (esaustivo ma costoso) - Random search (più efficiente) - Bayesian optimization - Learning rate finder