

Applicazioni Biomediche delle CNN

Dalla Classificazione alla Segmentazione

Le CNN viste finora **classificano** un'intera immagine:

Input: immagine $\rightarrow$ Output: classe (singolo valore)

In campo biomedico spesso serve la **segmentazione semantica**:

Input: immagine $\rightarrow$ Output: mappa di classi (stessa dimensione dell'input)

Ogni pixel viene classificato in una delle K classi (es. background, organo, lesione).

Info: Relazione con Segmentazione Classica Questo approccio basato su deep learning si affianca ai metodi classici di segmentazione come K-means, FCM e Region Growing, Level Set, Watershed. I metodi DL eccellono quando si hanno sufficienti dati annotati; i metodi classici sono preferibili per problemi ben definiti o con pochi dati.

Object Detection

Se l'immagine contiene **più oggetti** distinti, prima della classificazione è necessaria la **object detection**.

Approccio Semplice: Cropping

Se gli oggetti sono pochi e localizzati: - Definire regioni rettangolari (bounding box) - Classificare ogni regione separatamente

Approcci Avanzati

- **R-CNN**: regioni proposte + classificazione
 - **YOLO**: detection in un singolo passaggio
 - **Faster R-CNN**: Region Proposal Network integrata
-

Semantic Segmentation con CNN

Il Problema

Una CNN classica **riduce** le dimensioni dell'immagine:

$$H \times W \times C \rightarrow 1 \times 1 \times K$$

Per la segmentazione servono dimensioni **uguali** all'input:

$$H \times W \times C \rightarrow H \times W \times K$$

L'Idea dell'Autoencoder

Un **autoencoder** ha due parti:

1. **Encoder**: comprime l'input (come una CNN classica)
2. **Decoder**: ricostruisce l'immagine dalla rappresentazione compressa

!Pasted image 20251201192321.png

Attenzione: Problema La compressione causa **perdita di dettaglio** spaziale, inadatta per segmentazione accurata.

U-Net

La **U-Net** (Ronneberger et al., 2015) è l'architettura di riferimento per la segmentazione di immagini biomediche.

Caratteristiche Distintive

1. **Architettura a U** simmetrica
2. **Skip connections** tra encoder e decoder
3. Progettata per funzionare con **pochi dati** di training

Architettura

Input (572×572×1)

↓

ENCODER
(contracting path)

CONV→CONV→POOL ×4

↓

BOTTLENECK
(1024 features)

↓

DECODER
(expanding path)

UPCONV→CONCAT→CONV→CONV ×4

↓

Output (388×388×K)

!Pasted image 20251201192336.png

Encoder (Contracting Path)

Simile a una CNN classica: - Blocchi: **CONV** → **ReLU** → **CONV** → **ReLU** → **MaxPool** - Ogni blocco raddoppia il numero di feature - MaxPool dimezza le dimensioni spaziali

Decoder (Expanding Path)

Ricostruisce le dimensioni: - **Up-convolution** (transposed convolution): raddoppia le dimensioni - **Concatenazione** con feature dell'encoder (skip connection) - **CONV** → **ReLU** → **CONV** → **ReLU**

Skip Connections

Le **skip connections** sono fondamentali: - Collegano layer dell'encoder ai corrispondenti del decoder - Preservano i **dettagli spaziali** persi nella compressione - Permettono al decoder di usare feature a **diverse risoluzioni**

Suggerimento: Intuizione L'encoder cattura il “cosa” (feature semantiche), le skip connections aggiungono il “dove” (localizzazione precisa).

Implementazione U-Net

MATLAB

```
% Definizione semplificata U-Net
layers = [
    % Encoder
    imageInputLayer([256 256 1])
    convolution2dLayer(3,64,'Padding','same')
    reluLayer
    convolution2dLayer(3,64,'Padding','same')
    reluLayer
    maxPooling2dLayer(2,'Stride',2)

    % ... blocchi encoder aggiuntivi ...

    % Bottleneck
    convolution2dLayer(3,512,'Padding','same')
    reluLayer

    % Decoder (con skip connections)
    transposedConv2dLayer(2,256,'Stride',2)
    % concatenazione con encoder features
    convolution2dLayer(3,256,'Padding','same')
    reluLayer
```

```

% ... blocchi decoder aggiuntivi ...

% Output
convolution2dLayer(1,K) % K classi
softmaxLayer
pixelClassificationLayer()
];

```

Loss Function per Segmentazione

Cross-entropy per pixel:

$$L = -\frac{1}{N_{pixel}} \sum_{i,j} \sum_k t_{ijk} \log(p_{ijk})$$

Dove: - t_{ijk} = ground truth (one-hot) per pixel (i,j) classe k - p_{ijk} = probabilità predetta

Dice Loss (più robusta a sbilanciamento classi):

$$L_{Dice} = 1 - \frac{2|P \cap G|}{|P| + |G|}$$

Metriche di Valutazione per Segmentazione

Pixel Accuracy

$$\text{Accuracy} = \frac{\text{pixel corretti}}{\text{pixel totali}}$$

Attenzione: Problema Con classi sbilanciate (es. 95% background), accuracy alta non indica buona segmentazione.

IoU (Intersection over Union)

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|}$$

Dove P = predizione, G = ground truth.

Dice Coefficient

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|} = \frac{2 \times \text{IoU}}{1 + \text{IoU}}$$

Info: Relazione con Validazione Queste metriche corrispondono a quelle viste nel capitolo sulla Validazione degli Algoritmi.

Applicazioni Biomediche

Segmentazione di Organi

- **Cuore:** ventricoli, atri, miocardio
- **Cervello:** sostanza grigia/bianca, lesioni
- **Fegato:** parenchima, vasi, tumori
- **Polmoni:** parenchima, noduli

Segmentazione di Lesioni

- Tumori
- Placche aterosclerotiche
- Lesioni traumatiche

Quantificazione

Dalla segmentazione si possono calcolare: - **Volumi** degli organi/lesioni - **Forma** (sfericità, compattezza) - **Texture** (analisi regionale)

Varianti di U-Net

U-Net++

- Skip connections **dense** a più livelli
- Migliore fusione di feature multi-scala

Attention U-Net

- **Attention gates** nelle skip connections
- Focus automatico sulle regioni rilevanti

3D U-Net

- Per volumi (CT, MRI 3D)
- Stesso principio, operazioni 3D

nnU-Net

- Framework **auto-configurante**
 - Sceglie automaticamente preprocessing, architettura, training
 - State-of-the-art su molti benchmark biomedici
-

Sfide nell'Imaging Biomedico

Dataset Limitati

Attenzione: Il Problema Fondamentale I dataset biomedici sono tipicamente molto più piccoli di ImageNet.

Soluzioni: - Data augmentation aggressiva - Transfer learning - Semi-supervised learning - Active learning

Annotazioni Costose

L'annotazione pixel-wise richiede **esperti clinici** → molto costosa.

Soluzioni: - Weak supervision (label a livello di immagine) - Self-supervised pretraining

Variabilità

Immagini da scanner/protocolli diversi hanno caratteristiche diverse.

Soluzioni: - Domain adaptation - Harmonization - Training multi-centro

Interpretabilità

In clinica, serve capire **perché** la rete ha fatto una certa predizione.

Soluzioni: - Grad-CAM (activation visualization) - Uncertainty quantification - Explainable AI

Risorse e Tool

Framework

- **MONAI** (Medical Open Network for AI): framework PyTorch per medical imaging
- **nnU-Net**: framework auto-configurante
- **TorchIO**: preprocessing e augmentation per volumi 3D

Dataset Pubblici

Dataset	Modalità	Task
BRATS	MRI	Tumori cerebrali
LIDC-IDRI	CT	Noduli polmonari
ACDC	MRI cardiaca	Segmentazione cuore
ISIC	Dermatoscopia	Lesioni cutanee
