

Segmentazione a Soglia (*Thresholding*)

Nella **segmentazione a soglia**, ogni pixel viene associato a un tipo di tessuto basandosi unicamente sulla sua **intensità di segnale**. Questo processo equivale a scegliere **una o più soglie** nell'istogramma dell'immagine per classificare i pixel.

Meccanismo e Applicazione

Considerando l'immagine biomedica e il suo istogramma, la segmentazione a soglia opera come segue:

1. **Identificazione delle Classi:** Si identificano i picchi nell'istogramma, dove ciascun picco descrive la distribuzione del segnale associato a una specifica classe di tessuto. Il numero di soglie necessarie è $N - 1$, dove N è il numero di classi da distinguere.
2. **Scelta delle Soglie:** Fissando le soglie $T_1, T_2, \dots, T_{N-1}$, l'immagine viene suddivisa. Ad esempio, per tre classi (sfondo, acqua, olio) e due soglie ($T_1 = 90$, $T_2 = 500$):
 - **Classe 1 (Sfondo):** $s < T_1$
 - **Classe 2 (Acqua):** $T_1 \leq s < T_2$
 - **Classe 3 (Olio):** $s \geq T_2$
3. **Creazione delle Maschere:** Per ogni classe, si crea una maschera (*mask*) binaria in cui i pixel che soddisfano la condizione di soglia sono posti a un valore non nullo, e gli altri a zero.




Figura 1: Pasted image 20251129202220.png

Limiti Fondamentali della Segmentazione a Soglia

L'esempio pratico evidenzia i limiti intrinseci di questo metodo:

1. **Impossibilità di Distinguere per Topologia:** La segmentazione a soglia **non è in grado di distinguere oggetti topologicamente diversi** ma ai quali è associato lo stesso livello di segnale.
 - **Problema Clinico:** Nell'esempio, i *pattern* 1-3-6 e 2-6 non sono distinguibili. Questo è critico in applicazioni cliniche dove due strutture vicine hanno la stessa intensità (es. ventricolo destro e sinistro nel cuore, grasso viscerale e grasso sottocutaneo). Questo è un **limite intrinseco** del metodo.
2. **Pixel Spuri (Rumore):** Possono apparire pixel spuri o assegnazioni erranee. Questo è dovuto all'**imperfetta separazione dei picchi** nell'istogramma, spesso indotta dalle variazioni di segnale generate dal **rumore**. La qualità dipende dal **Contrasto-Rumore (CNR)** tra i tessuti da separare.
3. **Definizione Manuale della Soglia:** Le soglie vengono spesso definite **manualmente** tramite esame visivo dell'istogramma.

Soluzioni e Approcci Correttivi

I limiti della segmentazione a soglia possono essere mitigati combinando questo approccio con algoritmi successivi:

- **Superamento del Limite Topologico (1):** Questo limite può essere superato applicando algoritmi di tipo **topologico** alle maschere prodotte, come l'algoritmo di **labeling** (*connected components labeling*), che è in grado di distinguere oggetti spazialmente separati anche se appartengono alla stessa classe di intensità.
- **Correzione degli Errori di Rumore (2):** Gli errori di segmentazione indotti dal rumore possono essere corretti applicando algoritmi di **filtraggio** al risultato della segmentazione.
- **Ricerca Automatica della Soglia (3):** Esistono vari approcci automatici che consentono di trovare la soglia "ottima" che divide i pixel in classi. Tali algoritmi adottano un approccio di **apprendimento non supervisionato** (*unsupervised learning*).

Algoritmo di Otsu

L'algoritmo di **Otsu** è un metodo di segmentazione a soglia non supervisionato, automatico, che trova la soglia ottimale nell'istogramma di un'immagine.

Principio di Ottimizzazione

Nella sua versione originale, l'algoritmo di Otsu presume che nell'immagine da segmentare siano presenti **due sole classi** (background e foreground). Successivamente, può essere esteso a più classi (*multi Otsu method*).

L'algoritmo cerca di trovare la soglia t che separi l'immagine in due sottoclassi che siano il più possibile omogenee al loro interno.

Varianza Intra-Classe e Inter-Classe

L'algoritmo standard di Otsu calcola la soglia ottima **minimizzando la varianza intra-classe** (σ_W^2):

$$\sigma_W^2(t) = \omega_1(t)\sigma_1^2(t) + \omega_2(t)\sigma_2^2(t)$$

dove:

- $\omega_i(t)$ è la probabilità (o peso) di una classe separata dall'altra dalla soglia t .
- $\sigma_i^2(t)$ è la varianza (SD al quadrato) della classe i .

Si dimostra che **minimizzare la varianza intra-classe è equivalente a massimizzare la varianza inter-classe** (σ_B^2):

$$\sigma_B^2(t) = \omega_1(t)(\mu_1(t) - \mu_T)^2 + \omega_2(t)(\mu_2(t) - \mu_T)^2$$

dove:

- $\mu_i(t)$ è il valor medio di una classe.
- μ_T è il valore medio globale dell'immagine.

Intuitivamente, immaginando un istogramma a due picchi, il metodo di Otsu consiste nel trovare la soglia t intermedia tra i due picchi che li divida in modo ottimale.

Implementazione Algoritmica (Ricerca Esaustiva)

Il metodo di Otsu opera secondo un processo di **ottimizzazione basato sulla ricerca esaustiva** su tutti i possibili valori del parametro t .

Passaggi Algoritmici:

1. **Calcolo dell'Istogramma:** Si calcola l'istogramma h dell'immagine. La probabilità $p(i)$ di un livello di grigio i si ottiene normalizzando l'istogramma per il numero totale di pixel dell'immagine.
2. **Calcolo della Varianza per Ogni t :** Per ogni soglia t (da 0 al massimo livello di grigio) si calcolano i pesi e le medie delle due classi:
 - Classe 1 (inferiore o uguale a t):

$$\omega_1(t) = \sum_{i=0}^t p(i) \quad \mu_1(t) = \frac{\sum_{i=0}^t i \cdot p(i)}{\omega_1(t)}$$

- **Classe 2 (superiore a t):** $\omega_2(t)$ e $\mu_2(t)$ si calcolano in modo analogo operando le somme da $t + 1$ in avanti. Si calcola poi $\sigma_B^2(t)$.

3. **Selezione della Soglia Ottimale:** Si sceglie il t che **massimizza** $\sigma_B^2(t)$.

In questo modo, la soglia t viene definita in modo **automatico**.

Efficienza e Considerazioni Finali

- **Efficienza Computazionale:** Il calcolo della quantità $\sigma_B^2(t)$ è molto rapido, permettendo al calcolo di t di essere effettuato in **tempi ragionevoli**.
- **Dipendenza dalla Profondità:** Il tempo di calcolo è fortemente dipendente dalla **profondità dell'immagine** (numero di livelli di grigio).
- **Soglie Multiple:** Possono esistere più valori di t per cui $\sigma_B^2(t)$ è massima. In questi casi, l'algoritmo restituisce il **valor medio** tra i valori di t che massimizzano $\sigma_B^2(t)$.


In MATLAB, il metodo di Otsu è implementato nella funzione `otsuthresh` (quando si utilizza l'istogramma) o `graythresh` (quando si opera direttamente sull'immagine).

Introduzione al Clustering

Il **Clustering** è una tecnica di analisi dei dati volta alla selezione e raggruppamento di elementi omogenei in un insieme di dati. L'approccio è del tipo **unsupervised**, nel senso che l'algoritmo di clustering riesce a dividere i dati in una serie di insiemi avendo come unico input il numero di insiemi da trovare.

Nel campo dell'analisi delle immagini biomediche:

- Le **righe** della tabella rappresentano le locazioni spaziali (pixel/voxel)
- Le **colonne** rappresentano i valori di segnale acquisiti



Classificazione degli Algoritmi di Clustering

1. **Clustering esclusivo (K-means):** Un dato deve appartenere ad uno ed un solo cluster
2. **Clustering non esclusivo (Fuzzy C-Means):** Un dato può appartenere a più cluster con diversi gradi di appartenenza
3. **Clustering probabilistico (EM):** Basato su modelli probabilistici delle distribuzioni

Algoritmo K-means per il Clustering

L'algoritmo **K-means** (MacQueen, 1967) è un algoritmo base di **apprendimento non supervisionato** utilizzato per la classificazione dei dati.

Funzione Obiettivo e Complessità

Dato un insieme di dati $Y = \{y_1, \dots, y_n\}$ da classificare in C gruppi (cluster) e una distanza $\|\cdot\|$ definita su Y , l'algoritmo mira a minimizzare la seguente **funzione obiettivo** (J):

$$J = \sum_{j \in \Omega} \sum_{k=1}^C \|y_{jk} - v_k\|^2$$

dove:

- y_{jk} è un dato y_j assegnato al cluster k

- v_k è il **centroide** del cluster k

La funzione J è un indicatore della distanza complessiva dei dati dai centri dei rispettivi cluster.

- **Complessità:** Il problema di trovare l'assegnazione che realizza il minimo assoluto di J è **NP-completo**, con complessità computazionale $\mathcal{O}(n^{dC+1} \log n)$.

Procedura Iterativa K-means

L'algoritmo K-means è un ottimizzatore locale e richiede la definizione iniziale del numero di cluster C .

Passaggi Principali:

1. **Inizializzazione:** Assegnare un valore iniziale ai C centroidi v_k (in modo casuale, ma sufficientemente lontani tra loro).
2. **Iterazione** (Ripetuta finché i v_k si stabilizzano):
 - **Assegnazione:** Assegnare ogni dato y a uno e un solo cluster sulla base della distanza minima dal centroide.
 - **Aggiornamento:** Aggiornare i valori dei centroidi v_k calcolandoli come il centro di massa dei dati appartenenti al cluster k .

L'algoritmo **converge sempre**, ma la configurazione finale non è garantita essere il **minimo assoluto**.

Dipendenza dalle Condizioni Iniziali

Poiché l'algoritmo K-means è un **ottimizzatore locale**, lo stato di convergenza dipende dalla definizione iniziale dei centroidi.

- **Strategia di Ottimizzazione:** Ripetere il procedimento più volte (`nreplicates` in MATLAB) assegnando valori iniziali casuali e scegliendo la configurazione finale che minimizza il valore di J .

Aspetti Implementativi e Difficoltà

L'algoritmo K-means è implementato in MATLAB nella funzione `kmeans`. Difficoltà operative:

- **Inizializzazione dei Centroidi:** Necessario un metodo di inizializzazione (opzione `start`)
- **Dipendenza dal Risultato Iniziale:** Risolvibile con opzione `nreplicates`
- **Svuotamento dei Cluster:** Gestito dall'opzione `EmptyAction`





- **Scelta della Metrica:** Opzione Distance
- **Numero di Cluster (C):** Parametro di input predefinito

Varianti

Una variante del K-means è l'algoritmo **ISODATA** (*Iterative Self-Organizing Data Analysis Technique*), dove il numero di cluster C **non è un parametro fisso** ma viene computato dinamicamente.

Applicazione alla Segmentazione di Immagini

Nel *clustering* di immagini, la metrica utilizzata è tipicamente la **differenza assoluta** o la **media quadratica delle differenze** dei livelli di grigio.



Clustering Non Esclusivo (FCM)

Nel **clustering non esclusivo** (*fuzzy clustering*), un dato può appartenere a **più cluster** contemporaneamente, con diversi **livelli di appartenenza**. La somma dei livelli di appartenenza per un dato su tutti i possibili cluster deve essere 1.

Fondamenti Teorici: Logica Fuzzy

L'algoritmo **Fuzzy C-Means (FCM)** generalizza il K-means introducendo la **Logica Fuzzy** (o Logica Sfumata), ideata da Lotfi Zadeh.

- **Grado di Verità:** La Logica Fuzzy si basa su un **grado di verità** o **valore di appartenenza** (u) che può assumere valori **intermedi** tra 0 e 1.
- **Contrasto con la Probabilità:** Il concetto di appartenenza *fuzzy* non ha nulla a che vedere con la probabilità. Nella probabilità un'affermazione è vera o falsa con una certa probabilità; nella logica *fuzzy* è **insieme vera e falsa** con un certo grado.

Funzione Obiettivo e Parametro Fuzzyness

L'algoritmo FCM (Dunn, 1973; Bezdek, 1981) minimizza:

$$J_{FCM} = \sum_{j \in \Omega} \sum_{k=1}^C u_{jk}^m \|y_j - v_k\|^2$$

dove:

- u_{jk} è il **grado di appartenenza** di y_j al cluster k
- m è il parametro **fuzzyness**, tipicamente $m = 2$

Se u è una matrice binaria, la funzione J_{FCM} diviene uguale alla funzione $J_{K-means}$.

Aggiornamento Iterativo

Le formule di aggiornamento sono:

$$u_{j,k} = \frac{1}{\sum_{q=1}^C \left(\frac{\|y_j - v_k\|}{\|y_j - v_q\|} \right)^{\frac{2}{m-1}}}$$
$$v_k = \frac{\sum_{j=1}^N u_{jk}^m y_j}{\sum_{j=1}^N u_{jk}^m}$$

L'algoritmo è implementato in MATLAB nella funzione `fcm`.

Rilevanza Clinica: Gestione del PVE

L'approccio FCM è di grande interesse nella segmentazione delle immagini mediche perché consente di tenere conto dell'**Effetto Volume Parziale (PVE)**.

L'approccio FCM consente di assegnare a pixel con segnale misto un **valore di appartenenza distribuito** tra i tessuti presenti, **interpretando in modo corretto il PVE**.

Algoritmo EM (Expectation Maximization)

L'**Algoritmo EM** introduce il **clustering basato su modelli** per superare i limiti degli algoritmi tradizionali, includendo informazioni sulla distribuzione di probabilità dei vari cluster.

L'Approccio Basato su Modelli

La distribuzione dei dati all'interno dei singoli cluster viene modellata utilizzando **funzioni probabilistiche note**. L'insieme dei dati totale è modellato come una **combinazione lineare** di queste distribuzioni componenti:

$$h(s) = \sum_{k=1}^K P_k G(s|M_k, \sigma_k)$$

Dove:

- $h(s)$ è l'istogramma
- K è il numero delle classi
- P_k è la probabilità "a priori" della classe k
- $G(s|M_k, \sigma_k)$ è la distribuzione gaussiana per la classe k

Funzionamento dell'Algoritmo EM

Il procedimento iterativo si compone di due passi principali:

Passo E (Expectation)

Calcolo della **probabilità che il dato x_j sia stato generato dalla gaussiana i** :

$$p_{ij} = P_i G(x_j|M_i, \sigma_i)$$

Passo M (Maximization)

Aggiornamento dei parametri delle gaussiane:

$$\mu_i \leftarrow \frac{1}{p_i} \sum_j p_{ij} x_j$$

$$\sigma_i \leftarrow \frac{1}{p_i} \sum_j p_{ij} (x_j - \mu_i)^2$$

$$P_i \leftarrow \frac{p_i}{\sum_k p_k}$$

L'algoritmo EM-GM è implementato in Matlab dalla funzione `fitgmdist`.

Clustering Gerarchico

Il clustering gerarchico costruisce una struttura ad albero (dendrogramma) che rappresenta le relazioni di similarità tra i dati.

Esempio Pratico: Single-Linkage

Consideriamo cinque punti dati P_1, P_2, P_3, P_4, P_5 con matrice delle distanze:

	P1	P2	P3	P4	P5
P_1	0	2.0	6.0	7.0	9.0
P_2	2.0	0	5.0	6.5	8.0
P_3	6.0	5.0	0	2.5	3.5
P_4	7.0	6.5	2.5	0	1.0
P_5	9.0	8.0	3.5	1.0	0

Iterazioni:

1. $L(1) = 1.0$: Fusione (P_4, P_5)
2. $L(2) = 2.0$: Fusione (P_1, P_2)
3. $L(3) = 2.5$: Fusione ($P_3, (P_4, P_5)$)
4. $L(4) = 5.0$: Fusione finale

Il metodo **Single-Linkage** tende a formare “catene” di punti, in quanto è sufficiente che due membri dei cluster siano vicini per innescare la fusione.

Metriche negli Algoritmi di Clustering

La scelta della **metrica** è cruciale, poiché definisce come viene misurata la **differenza (o distanza)** tra due punti.

La Famiglia delle Distanze di Minkowski

$$d(\mathbf{x}_i, \mathbf{x}_j) = \left(\sum_{q=1}^K |x_{iq} - x_{jq}|^p \right)^{\frac{1}{p}}$$

Casi Particolari

- **Distanza Euclidea** ($p = 2$): Distanza in linea retta
- **Distanza Manhattan** ($p = 1$): Somma delle differenze assolute
- **Distanza di Chebyshev** ($p \rightarrow \infty$): Massima differenza tra le coordinate

Altre Metriche Comuni

Metrica	Applicazione Tipica
Correlazione	Segmentazione di immagini 2D+T (curve temporali)
Distanza di Mahalanobis	Variabili con scale diverse o correlate
Distanza di Jaccard	Dati binari o set di attributi

Importanza della Normalizzazione

Se i dati non sono omogenei, è opportuno applicare la **standardizzazione delle variabili** (Z-Score):

$$z = \frac{x - \mu}{\sigma}$$

In MATLAB: funzioni zscore o normalize.

TABLE I
SIMILARITY AND DISSIMILARITY MEASURE FOR QUANTITATIVE FEATURES

Measures	Forms	Comments	Examples and Applications
Minkowski distance	$D_{ij} = \left(\sum_{l=1}^d x_{il} - x_{jl} ^n \right)^{1/n}$	Metric. Invariant to any translation and rotation only for $n=2$ (Euclidean distance). Features with large values and variances tend to dominate over other features.	Fuzzy c -means with measures based on Minkowski family [130].
Euclidean distance	$D_{ij} = \left(\sum_{l=1}^d x_{il} - x_{jl} ^2 \right)^{1/2}$	The most commonly used metric. Special case of Minkowski metric at $n=2$. Tend to form hyperspherical clusters.	K -means algorithm [191]
City-block distance	$D_{ij} = \sum_{l=1}^d x_{il} - x_{jl} $	Special case of Minkowski metric at $n=1$. Tend to form hyperrectangular clusters.	Fuzzy ART [57]
Sup distance	$D_{ij} = \max_{1 \leq l \leq d} x_{il} - x_{jl} $	Special case of Minkowski metric at $n \rightarrow \infty$.	Fuzzy c -means with sup norm [39].
Mahalanobis distance	$D_{ij} = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{S}^{-1} (\mathbf{x}_i - \mathbf{x}_j)$, where $\mathbf{S}$ is the within-group covariance matrix.	Invariant to any nonsingular linear transformation. $\mathbf{S}$ is calculated based on all objects. Tend to form hyperellipsoidal clusters. When features are not correlated, squared Mahalanobis distance is equivalent to squared Euclidean distance. May cause some computational burden.	Ellipsoidal ART [13], Hyperellipsoidal clustering algorithm [194].
Pearson correlation	$D_{ij} = (1 - r_{ij})/2$, where $r_{ij} = \frac{\sum_{l=1}^d (x_{il} - \bar{x}_i)(x_{jl} - \bar{x}_j)}{\sqrt{\sum_{l=1}^d (x_{il} - \bar{x}_i)^2 \sum_{l=1}^d (x_{jl} - \bar{x}_j)^2}}$	Not a metric. Derived from correlation coefficient. Unable to detect the magnitude of differences of two variables.	Widely used as the measure for analyzing gene expression data [80].
Point symmetry distance	$D_{ir} = \min_{j \neq i, j \neq r} \frac{\ (\mathbf{x}_i - \mathbf{x}_r) + (\mathbf{x}_j - \mathbf{x}_r)\ }{\ (\mathbf{x}_i - \mathbf{x}_r)\ + \ (\mathbf{x}_j - \mathbf{x}_r)\ }$	Not a metric. Compute the distance between an object $\mathbf{x}_i$ and a reference point $\mathbf{x}_r$. D_{ir} is minimized when a symmetric pattern exists.	SBKM (Symmetry-based K -means) [264].
Cosine similarity	$S_{ij} = \cos \alpha = \frac{\mathbf{x}_i^T \mathbf{x}_j}{\ \mathbf{x}_i\ \ \mathbf{x}_j\ }$	Independent of vector length. Invariant to rotation, but not to linear transformations.	The most commonly used measure in document clustering [261].

Figure 2: Pasted image 20251129203740.png