

Misure Statistiche di Precisione e Riproducibilità

Come detto in precedenza, la valutazione di un algoritmo di segmentazione si basa su prove ripetute su di un certo numero di immagini considerate rappresentative delle immagini su cui verrà utilizzato l'algoritmo. Supponiamo di voler valutare la congruenza di due metodi nell'analisi di un certo tipo di immagini. Prendiamo K immagini e utilizziamo il metodo 1 per estrarre dalle K immagini K indici ed un secondo metodo per effettuare la stessa procedura senza conoscere i risultati del primo metodo. Avremo una prima serie di indici $x_1, x_2, \dots, x_K$ ed una seconda serie $y_1, y_2, \dots, y_K$. In teoria, gli indici dovrebbero essere uguali a coppie ($x_1=y_1, x_2=y_2, \dots$). I due metodi possono corrispondere a due operatori umani, ed in questo caso il confronto delle misure fornisce una stima della variabilità (o riproducibilità) inter-osservatore. Se i due metodi rappresentano le misure fatte in tempi diversi dallo stesso osservatore umano viene stimata la variabilità intra-osservatore. Se il confronto è tra un algoritmo ed un gold standard il confronto delle misure fornisce una stima della correttezza o precisione dell'algoritmo.


Osservatore 1 vs Osservatore 1	Riproducibilità Intra-osservatore
Osservatore 1 vs Osservatore 2	Riproducibilità Inter-osservatore
Algoritmo vs Osservatore	Precisione dell'algoritmo
Algoritmo (test 1) vs Algoritmo (test 2)	Riproducibilità dell'algoritmo

Se il funzionamento dell'algoritmo dipende da un input dell'osservatore (algoritmo semi-automatico) o da fattori casuali (condizioni iniziali random) si definisce la riproducibilità dell'algoritmo confrontando i risultati di due o più test successivi sugli stessi dati di ingresso. Un algoritmo totalmente automatico (unsupervised), cioè che non dipende in nessun modo dall'input dell'utente può essere perfettamente riproducibile. Per confrontare le misure si possono utilizzare diversi indici. Il primo indice utilizzato è il cosiddetto Coefficiente di Variazione (Coefficient of Variation, CoV o CV). Il CoV valuta quanto pesa percentualmente la differenza tra due misure ed è misurato come la deviazione standard del vettore degli errori percentuali assoluti sulle singole misure. Valuteremo quindi l'errore percentuale assoluto come $epi = 100 \times ASS(x_i, y_i) / MEAN(x_i, y_i)$ e poi calcoleremo la deviazione standard del vettore epi. Il procedimento nel calcolo della CoV è identico nel caso si confronti una misura con un gold standard, con la differenza che al posto della media delle misure avremo la misura effettuata con il gold standard che si considera quella corretta. Una $CoV < 10\%$ è di solito considerata accettabile in campo medico. Questo tipo di misura ci fornisce l'errore percentuale atteso che commette un osservatore o un algoritmo quando esamina due volte la stessa immagine. Non ci dice però quanto è grave l'errore da un punto di vista diagnostico, in quanto ad esempio un errore del 10% può essere trascurabile su di un indice che varia del 100% tra un caso normale ed uno patologico mentre è grave se la variazione è ad esempio del 20%. Inoltre

la CoV non tiene conto della differenza tra errore casuale ed errore sistematico. Per errore sistematico intendiamo il fatto che uno dei due operatori sottostimi o sovrastimi sempre l'indice estratto. L'errore sistematico è meno grave dell'errore casuale, in quanto mantiene l'ordine degli indici estratti che è un fattore diagnostico importante. Un altro indice spesso utilizzato nella comparazione di indici diagnostici è la correlazione tra le due misure. Pensiamo che esista una relazione lineare tra le osservazioni $X=(x_1, x_2, \dots, x_K)$ e $Y=(y_1, y_2, \dots, y_K)$. Avremo quindi


$$y_i = a + bx_i + \varepsilon_i$$

Quindi la variabile dipendente y viene "spiegata" attraverso una relazione lineare della variabile indipendente x (cioè: $a+bx$) e da una quantità casuale ε_i che rappresenta il rumore della misura. L'indice a rappresenta il fatto che un operatore aggiunge una certa quantità rispetto all'altro, il fattore b il fatto che un operatore sovrastima l'indice in una certa misura. Il ben noto problema della regressione si traduce nella determinazione di a e b in modo da esprimere al 'meglio' la relazione funzionale tra Y e X . Tipicamente si calcolano i coefficienti a e b secondo il metodo dei minimi quadrati utilizzando opportuni software statistici. E' possibile estendere il metodo a più variabili (caso multivariato).



S
deriva quindi una retta che interpola uno scatter di punti minimizzando la somma dei quadrati delle distanze ε_i dei punti stessi dalla retta. In questo esempio il confronto è tra due osservatori, uno umano (manual) ed uno automatico (auto). Il fatto che le

misure siano vicine alla retta di regressione da una informazione visuale sul fatto che i due osservatori forniscono risultati simili. In questo caso la misura manuale funge da “gold standard”. La variabilità inter- e intra-osservatore si calcolano in modo analogo. Chiaramente oltre alla rappresentazione grafica è utile avere un indice numerico della bontà del fitting. L' R^2 , o coefficiente di determinazione, è una misura della bontà dell'adattamento (in inglese fitting) della regressione lineare stimata ai dati osservati. L' R^2 misura la frazione della variabilità delle osservazioni y_i che siamo in grado di spiegare tramite il modello lineare. Bisogna notare che l' R^2 non misura se effettivamente sussista una relazione (di qualsiasi tipo) tra le y_i e i regressori, ma soltanto fino a che punto un modello lineare consente di approssimare la realtà dei dati osservati; un modello non lineare, ad esempio, potrebbe meglio rappresentare la relazione tra variabile dipendente e regressori, e presentare un buon potere esplicativo, anche in presenza di un R^2 prossimo allo zero. Nella retta di regressione in figura ad esempio $r=0.93$. Un altro parametro importante è la pendenza della retta b , che idealmente deve essere uguale ad 1. Se b è diverso da uno, uno dei due metodi sottostimerà o sovrastimerà la misura rispetto all'altro. L'intercetta a dovrebbe essere nulla, se non lo è esiste una differenza sistematica tra le misure. Un'altra rappresentazione grafica molto popolare è il cosiddetto Bland-Altman plot. In figura vediamo il grafico per le due serie di dati per cui era stata tracciata la retta di regressione. Nel BlandAltman plot, in ascisse abbiamo la media delle due misure, ed in ordinata la differenza delle stesse. La media delle differenze è riportata come una riga continua, e permette di stimare se una delle due metodiche sottostima o sovrastima l'indice rispetto all'altra. In questo caso vediamo che la metodica automatica da una stima inferiore rispetto a quella manuale. Le due righe indicate con $1.96SD$ e $-1.96SD$ sono ottenute calcolando la deviazione standard dei dati. Se i punti del grafico sono all'interno delle due linee si considera che le due metodiche forniscano risultati congruenti, mentre i punti fuori dalle due linee sono casi in cui i due metodi non sono congruenti tra loro. In particolare, si può verificare che se la distribuzione delle differenze è gaussiana il 95% dei dati cade nell'area indicata.



Il Bland-Altman plot può essere usato solo per confrontare misure della stessa natura. Nel caso il confronto sia fatto con un gold standard, sull'asse x viene riportato il gold standard e non la media delle misure.