

4.4.1 Test Statistici e Diagnosi

Questo capitolo tratta due aspetti fondamentali della validazione in ambito biomedico:

1. **Test di significatività statistica** - per determinare se le differenze osservate sono reali
 2. **Misure di efficacia diagnostica** - per valutare la capacità di identificare patologie
-

4.4.2 Test di Significatività Statistica

4.4.2.1 L'Ipotesi Nulla

Di larghissimo uso nella valutazione delle metodiche per l'estrazione di indici clinici è l'**indice p** (p-value), che rappresenta la probabilità di accettazione dell'**ipotesi nulla** (H_0).

□ **Info:** Definizione

L'**ipotesi nulla** afferma che non esiste alcuna differenza tra le due misure riguardo al parametro considerato. Le eventuali differenze osservate vanno attribuite al solo caso.

Implicazione clinica: Due misure statisticamente equivalenti possono essere usate in modo **interscambiabile** nella valutazione clinica.

4.4.2.2 Il Test di Significatività

L'ipotesi nulla può essere accettata o respinta applicando un **test statistico di significatività**:

1. Calcolare la statistica del test
2. Confrontare con un valore critico tabulato
3. Se il risultato **supera** il valore critico → differenza **statisticamente significativa** → H_0 respinta
4. Altrimenti → H_0 accettata

4.4.2.3 Il P-value

Il parametro **p** esprime la probabilità che l'ipotesi nulla sia falsa:

Valore p	Interpretazione
$p < 0.01$	Differenza altamente significativa
$p < 0.05$	Differenza significativa
$p \geq 0.05$	Differenza non significativa

□ **Attenzione:** Attenzione

Un p-value basso (es. $p < 0.05$) indica che i due gruppi sono **diversi**, non equivalenti. Nel caso della validazione, vogliamo $p \geq 0.05$ per confermare l'equivalenza.

4.4.2.4 Errori nei Test Statistici

Tipo	Nome	Descrizione	Probabilità
Tipo I	Falso Positivo	Rifiutare H_0 quando è vera	α (livello di significatività)
Tipo II	Falso Negativo	Accettare H_0 quando è falsa	β

La **potenza** del test è definita come $1 - \beta$: capacità di rilevare differenze reali.

4.4.2.5 Paired t-Test

Il **paired t-test** (test t per campioni appaiati) si applica quando la misura è effettuata:

- Da due osservatori sulla **stessa immagine**
- Con due metodi sullo **stesso paziente**

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}$$

dove:

- $\bar{d}$ = media delle differenze
- s_d = deviazione standard delle differenze
- n = numero di coppie

Applicazioni:

- Valutazione vs. gold standard
- Intra-observer variability
- Inter-observer variability

□ **Esempio:** Esempio Clinico: Misura del Ferro Epatico

Confronto tra due software per la misura dell'accumulo di ferro in pazienti talassemici (20 immagini):

Gruppo	p-value	Conclusione
Senza accumulo	$p = 0.0776$	Non significativo → metodi equivalenti

Gruppo	p-value	Conclusione
Con accumulo severo	$p < 0.0001$	Significativo → metodi diversi

Nota: Il paired t-test è sensibile all'**errore sistematico**. Una differenza di 0.55 su media 38.5 (1.5%) può già creare significatività.

4.4.2.6 Altri Test Statistici

Test	Applicazione	Requisiti
t-test indipendente	Gruppi diversi	Normalità, varianze omogenee
Wilcoxon signed-rank	Alternativa non parametrica al paired t-test	Dati ordinali
Mann-Whitney U	Alternativa non parametrica al t-test indipendente	Dati ordinali
ANOVA	Confronto > 2 gruppi	Normalità, varianze omogenee
Bland-Altman	Agreement tra metodi	Visualizzazione grafica

4.4.3 Misure di Efficacia Diagnostica

La validità di un metodo di analisi può essere valutata in base all'**efficacia nell'identificare una malattia**.

4.4.3.1 Matrice di Confusione

Data una popolazione di K pazienti:

- M = pazienti **malati**
- S = pazienti **sani** ($K = M + S$)

	Condizione Reale: Malato	Condizione Reale: Sano
Test Positivo	VP (Vero Positivo)	FP (Falso Positivo)
Test Negativo	FN (Falso Negativo)	VN (Vero Negativo)

4.4.3.2 Metriche Fondamentali

4.4.3.2.1 Sensibilità (Recall, True Positive Rate)

$$\text{Sensibilità} = \frac{VP}{VP + FN} = \frac{VP}{M}$$

Capacità del metodo di **scoprire la patologia**. Percentuale di diagnosi giuste sui soggetti **malati**.

4.4.3.2.2 Specificità (True Negative Rate)

$$\text{Specificità} = \frac{VN}{VN + FP} = \frac{VN}{S}$$

Capacità del metodo di fare una **diagnosi corretta sui pazienti sani**.

4.4.3.2.3 Accuratezza

$$\text{Accuratezza} = \frac{VP + VN}{VP + VN + FP + FN} = \frac{VP + VN}{K}$$

Percentuale totale di **diagnosi corrette**.

4.4.3.2.4 Valore Predittivo Positivo (Precisione)

$$PPV = \frac{VP}{VP + FP}$$

Probabilità che un test positivo sia corretto.

4.4.3.2.5 Valore Predittivo Negativo

$$NPV = \frac{VN}{VN + FN}$$

Probabilità che un test negativo sia corretto.

4.4.3.3 Trade-off Sensibilità vs Specificità

□ **Attenzione:** Compromesso Clinico

Alta sensibilità (pochi FN) → rischio di FP → sovra-diagnosi **Alta specificità** (pochi FP) → rischio di FN → sotto-diagnosi

La scelta dipende dal **contesto clinico** e dal rapporto **costo/beneficio** degli errori.

Scenario	Priorità
Screening tumori	Alta sensibilità (non perdere malati)
Test confermativi	Alta specificità (evitare falsi allarmi)

4.4.4 Curve ROC (Receiver Operating Characteristic)

4.4.4.1 Costruzione della Curva ROC

La **curva ROC** (Receiver Operating Characteristic) è lo strumento standard per valutare classificatori binari al variare della soglia decisionale e offre una visualizzazione del **trade-off** tra sensibilità e specificità al variare di una soglia decisionale.

La curva vive nello spazio (1 — Specificità, Sensibilità) ovvero (FPR, TPR):

$$\text{Sensibilità (TPR)} = \frac{TP}{TP + FN}, \quad \text{Specificità} = \frac{TN}{TN + FP}$$

I punti estremi rappresentano classificatori degeneri: (0, 0) predice sempre “negativo”, (1, 1) sempre “positivo”. La diagonale $y = x$ corrisponde a un classificatore random (AUC = 0.5).

Procedura:

1. Si ha un vettore $X = (x_1, x_2, \dots, x_N)$ di misure continue
2. Si ha un indice binario $I = (i_1, i_2, \dots, i_N)$ indicante presenza/assenza patologia
3. Si fa variare una soglia T
4. Per ogni T : si classificano come patologici i soggetti con $x > T$
5. Si calcolano sensibilità e specificità
6. Si riportano i punti nel grafico (1-Specificità, Sensibilità)

4.4.4.2 Interpretazione della Curva

Punto/Curva	Significato
Origine (0,0)	Osservatore che dice sempre “NO”
(1,1)	Osservatore che dice sempre “SI”
Diagonale	Test non informativo (casuale)
Curva → angolo superiore sinistro	Test ottimo

Per tracciare una curva ROC prenderemo un vettore $X = (x_1, x_2, \dots, x_N)$ continuo. Ad esempio x potrebbe essere una misura di perfusione nel miocardio. Avremo poi un indice

Sensitivity




Figura 1: Pasted Image 20260105170110.png

$I = (i_1, i_2, \dots, i_N)$ binario, che indica se il soggetto ha o non ha una certa patologia (ad esempio una stenosi coronarica). Facciamo variare una soglia T e definiamo patologici i soggetti con $X < T$ e sani quelli con $X > T$. Avremo dei valori di sensibilità e specificità che riporteremo nel grafico tracciando la curva ROC.

Notiamo che avremo sempre un punto nell'origine, corrispondente a sensibilità 0 e specificità 1. Questo punto equivale ad un osservatore che risponde sempre NO. L'osservatore che risponde sempre SI corrisponde al punto in alto a destra.

Tutti i punti della curva corrispondono ad un compromesso tra sensibilità e specificità, il punto migliore in generale dipende dal quesito clinico e dal rapporto costo/beneficio. È possibile comunque calcolare il punto con la massima accuratezza. Una curva corrispondente alla diagonale indica che l'indice non dà informazioni sulla patologia.

L'area della curva può essere usata come fattore di merito per la metodologia, e quindi in questo caso per il metodo di analisi dell'immagine.

4.4.4.3 Area Under the Curve (AUC)

L'**AUC** (Area Under Curve) sintetizza le performance in uno scalare $\in [0.5, 1]$:

$$AUC = \int_0^1 TPR(t) d(FPR(t))$$

AUC	Interpretazione
1.0	Classificatore perfetto
0.9 - 1.0	Eccellente
0.8 - 0.9	Buono
0.7 - 0.8	Discreto
0.5 - 0.7	Scarso
0.5	Casuale (nessun potere discriminativo)

L'AUC rappresenta la probabilità che un soggetto malato scelto casualmente abbia un valore del test maggiore di un soggetto sano scelto casualmente.

4.4.4.4 Punto Ottimale sulla Curva ROC


Il **punto operativo ottimale** dipende dal contesto clinico:

1. **Massima accuratezza:** punto più vicino all'angolo $(0, 1)$
2. **Youden's J statistic:** massimizza $J = \text{Sensibilità} + \text{Specificità} - 1$
3. **Costo-beneficio:** considera i costi relativi di FP e FN

$$\text{Distanza} = \sqrt{(1 - \text{Sensibilità})^2 + (1 - \text{Specificità})^2}$$

4.4.5 Applicazione alla Validazione Software

4.4.5.1 Workflow di Validazione



4.4.5.2 Metriche Riassuntive

Contesto	Metrica Principale
Misure continue	p-value (paired t-test), correlazione, Bland-Altman
Classificazione binaria	Sensibilità, Specificità, AUC
Multi-classe	Matrice di confusione, F1-score

4.4.6 Riepilogo

Concetto	Descrizione
P-value	Probabilità che H_0 sia vera; $p < 0.05 \rightarrow$ differenza significativa
Paired t-test	Test per confronto di misure appaiate
Sensibilità	$VP/(VP + FN)$ - capacità di identificare malati
Specificità	$VN/(VN + FP)$ - capacità di identificare sani
Curva ROC	Grafico sensibilità vs (1-specificità)
AUC	Area sotto la curva ROC; 1.0 = perfetto, 0.5 = casuale