

Mutua Informazione

La registrazione attraverso features ha come prerequisito la disponibilità di un efficace algoritmo di segmentazione che sia in grado di estrarre le stesse features dalle due immagini. Quando questo non è possibile, si utilizzano metriche che coinvolgono le immagini nella loro **globalità**. L'esempio più noto di queste metriche è la **mutua informazione**.

Fondamenti Probabilistici

Variabili Aleatorie Discrete

Si considera una **variabile aleatoria** X che può assumere solo valori appartenenti a Ω_X , un **sottoinsieme finito** dello spazio dei numeri interi.

□ **Info:** Applicazione alle Immagini

Se l'informazione è costituita dai **valori di segnale** di un'immagine, gli elementi di Ω_X corrispondono ai possibili valori del livello di grigio. La dimensione di Ω_X è uguale alla **profondità dell'immagine**.

Distribuzione di Probabilità

Alla variabile X è associata la funzione $P(X) : \Omega_X \rightarrow [0, 1]$, detta **distribuzione di probabilità**.

- $P(X = x_i)$ indica la probabilità che la variabile X valga x_i
- Questa distribuzione è ricavabile dall'**istogramma normalizzato dell'immagine**

Per una variabile aleatoria discreta vale:

$$\sum_{x_i \in \Omega_X} P(X = x_i) = 1$$

Calcolo di $P(X)$

Noti N campioni della variabile aleatoria X :

1. Valutare Ω_X (insieme dei valori possibili)
2. Contare il numero di volte in cui X assume ognuno degli S valori
3. Si ottiene un **istogramma** (array di S elementi)
4. **Normalizzare** dividendo per N

□ **Suggerimento:** Variabili Continue

Per variabili continue si scelgono intervalli (**bin**) in cui dividere l'insieme di definizione.

Dipendenza tra Variabili

Distribuzione Congiunta

Quando una variabile aleatoria è funzione di un'altra ($Y = F(X)$), si dice che X e Y sono **dipendenti**. In questo caso una misura di X consente di predire il valore di Y .

La dipendenza tra due variabili aleatorie può essere formalizzata esaminando la **distribuzione congiunta** $P(X, Y)$, che indica le co-occorrenze degli eventi di X e Y .

Distribuzioni Marginali

Nota $P(X, Y)$, è possibile ricavare le **distribuzioni di probabilità marginali**:

$$P(X) = \sum_{y_i \in \Omega_Y} P(X, Y = y_i)$$

$$P(Y) = \sum_{x_i \in \Omega_X} P(X = x_i, Y)$$

Indipendenza

Due variabili sono **indipendenti** se:

$$P(X, Y) = P(X) \cdot P(Y)$$

Se questa relazione non è valida, X e Y sono **dipendenti**.

Calcolo dell'Istogramma Congiunto

Per calcolare $P(X, Y)$ noti N campioni di X e di Y :

1. Creare un **istogramma bidimensionale** delle coppie $(X, Y) \in \Omega_{X,Y}$
2. Associare i campioni secondo la loro **corrispondenza spaziale**
3. **Normalizzare** dividendo per N

□ **Esempio:** Auto-correlazione

Se si calcola la distribuzione congiunta di un'immagine con sé stessa, si ottiene una matrice con valori non nulli solo sulla **diagonale** (i valori corrispondenti sono sempre identici).

Entropia

L'**entropia** è una funzione che misura la **casualità** di una variabile aleatoria: più una variabile è casuale, tanto maggiore è la sua entropia.

Intuizione

Consideriamo due distribuzioni di probabilità:

- **Distribuzione uniforme:** La variabile ha la stessa probabilità di assumere qualsiasi valore → **alta entropia**
- **Distribuzione concentrata (picco):** I valori sono concentrati intorno a un valore → **bassa entropia**

□ **Info:** Storia

Nonostante il concetto di entropia derivi dalla termodinamica, è stato applicato all'analisi dei dati dal **1948** grazie a **Shannon**.

Definizione Matematica

$$H(X) = -E_X\{\log[P(X)]\} = - \sum_{x_i \in \Omega_X} \log[P(X = x_i)] \cdot P(X = x_i)$$

dove:

- $\log$ indica il logaritmo in **base due**
- E_X è l'**aspettazione** (valore atteso)

□ **Attenzione:** Caso $P(X)=0$

Per gestire il caso $P(X) = 0$ si usa il limite notevole:

$$\lim_{x \rightarrow 0^+} x \cdot \log(x) = 0$$

Entropia Condizionale e Congiunta

Entropia Condizionale

$$H(Y|X) = -E_X \{E_Y \{\log[P(Y|X)]\}\}$$

Misura la **casualità di Y noto X**. Essendo un'aspettazione su differenti eventi di X, è una misura media.

Entropia Congiunta

$$H(X, Y) = - \sum_{x_i \in \Omega_X} \sum_{y_j \in \Omega_Y} \log[P(X = x_i, Y = y_j)] \cdot P(X = x_i, Y = y_j)$$

Caso di Indipendenza

Se X e Y sono **indipendenti**:

$$H(Y|X) = H(Y)$$
$$H(X, Y) = H(X) + H(Y)$$

□ **Suggerimento:** Dipendenza

Se aumenta la dipendenza di Y da X , $H(Y|X)$ **diminuisce**. Tuttavia l'entropia condizionale non può essere direttamente utilizzata come misura della dipendenza (potrebbe essere piccola semplicemente perché $H(Y)$ lo è).

Definizione di Mutua Informazione

La **Mutua Informazione** (MI), detta anche **entropia relativa**, calcola la quantità di informazione che una variabile aleatoria possiede riguardo ad un'altra.

Formula Principale

$$MI(X; Y) = H(X) + H(Y) - H(X, Y)$$

Formulazioni Alternative

$$MI(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

In base a queste equazioni, $MI(X; Y)$ è la **diminuzione dell'incertezza** sul valore di X una volta noto Y , ovvero è la quantità di informazione che Y contiene riguardo a X .

Distanza di Kullback-Leibler

La MI misura il grado di dipendenza calcolando la **distanza** tra la distribuzione congiunta $P(X, Y)$ e il caso di indipendenza completa:

$$MI(X; Y) = \sum_{X, Y} P(X, Y) \cdot \log \frac{P(X, Y)}{P(X) \cdot P(Y)}$$

Proprietà della Mutua Informazione

Proprietà	Formula
Non negativa	$MI(X; Y) \geq 0$
Indipendenza	$MI(X; Y) = 0 \iff P(X, Y) = P(X) \cdot P(Y)$

Proprietà	Formula
Simmetria	$MI(X; Y) = MI(Y; X)$
Auto-informazione	$MI(X; X) = H(X)$
Limite superiore	$MI(X; Y) \leq \min[H(X), H(Y)]$

□ **Suggerimento:** Vantaggio Principale

La MI **non utilizza alcuna ipotesi sulla linearità** della relazione tra le variabili, a differenza della correlazione.

Calcolo Pratico della MI

Entropia da Istogramma

Dato l'istogramma h di un'immagine Q con M pixel:

$$H(Q) = -\frac{1}{M} \sum_{i=1}^M \log \left[\frac{h_Q(i)}{M} \right] h_Q(i)$$

Entropia Congiunta da Istogramma Mutuo

Dato l'istogramma mutuo di due immagini Q e K :

$$H(Q, K) = -\frac{1}{M} \sum_{j=1}^M \sum_{i=1}^M \log \left[\frac{h_{QK}(i, j)}{M} \right] h_{QK}(i, j)$$

□ **Attenzione:** Area Comune

Il calcolo dell'entropia deve essere limitato all'**area comune** alle due immagini.

Implementazione MATLAB

Gli istogrammi possono essere calcolati con le funzioni `hist` e `hist3`.

Esempi Pratici

Caso 1: Immagini di Rumore

Se consideriamo due immagini di rumore gaussiano, l'istogramma mutuo è "piatto" senza picchi significativi. La MI assume un valore molto **basso** (teoricamente nullo).





Figura 1: Pasted image 20251201185524.png

Caso 2: Immagini Binarie Identiche

Per due immagini uguali binarie, le uniche coppie possibili sono nero-nero e bianco-bianco, formando due colonne nell'istogramma mutuo.

- **MI = 0.69** (significativamente diversa da zero)
- **RMSE = 0** (immagini identiche)





Figura 2: Pasted image 20251201185536.png

Caso 3: Immagini Binarie Ruotate

Le stesse immagini con una ruotata. Nell'istogramma mutuo compaiono le coppie bianco-nero e nero-bianco.

- **MI = 0.69** (identica al caso 2!)
- **RMSE $\neq$ 0** (immagini diverse)

□ **Suggerimento:** Invarianza della MI





Figura 3: Pasted image 20251201185547.png

La MI non è sensibile al cambio dei valori di segnale, al contrario dell'RMSE.

Caso 4: Immagini Roto-Traslate

Quando un'immagine è ruotata e traslata rispetto all'altra, compaiono tutte le coppie bianco/nero e l'istogramma doppio mostra quattro colonne.

- **MI = 0.19** (minore del caso allineato)
- Un ottimizzatore che massimizza la MI corregge lo sfasamento



In un caso reale in cui le immagini sono corrotte da rumore, i picchi dell'istogramma mutuo si allargheranno in dipendenza dal livello di rumore, ma il principio di funzionamento resterà inalterato.




Figura 4: Pasted image 20251201185559.png